

Trabalho Computacional de Teoria da Decisão

André Prado Procopio - approcopio@ufmg.br

Arthur Jorge Alves de Carvalho - arthurjorgeac@ufmg.br

Lucas Ribeiro da Silva - lucasrsilvak@ufmg.br

Milena Terra Lopes - milenatl@ufmg.br

I. INTRODUÇÃO

Este relatório aborda o Problema de Atribuição Generalizada (GAP), um desafio clássico de otimização combinatória NP-difícil. O objetivo é alocar um conjunto de tarefas a um grupo de agentes, sujeito a restrições de capacidade. A complexidade do problema reside em seus dois objetivos conflitantes: por um lado, a minimização do custo total de alocação e, por outro, a busca por um equilíbrio na carga de trabalho distribuída entre os agentes.

Para solucionar este problema, apresentamos uma modelagem matemática detalhada e desenvolvemos uma meta-heurística baseada no *Variable Neighborhood Search* (VNS). A metodologia inclui a proposição de uma heurística construtiva para a geração de uma solução inicial de qualidade, a definição de três estruturas de vizinhança distintas para a exploração do espaço de soluções e uma estratégia de refinamento que atua como busca local e garante a viabilidade das soluções. Por fim, são apresentados e analisados os resultados experimentais obtidos na otimização mono-objetivo de cada função, em seguida, utiliza-se a modelagem multi-objetivo com a utilização dos algoritmos de soma ponderada e ϵ -restrito.

II. MODELAGEM MATEMÁTICA

A seguir, são apresentadas as formulações matemáticas para os problemas de otimização.

DEFINIÇÃO DAS VARIÁVEIS E PARÂMETROS

- m : Número de agentes.
- n : Número de tarefas.
- i : Índice para os agentes, onde $i \in \{1, \dots, m\}$.
- j : Índice para as tarefas, onde $j \in \{1, \dots, n\}$.
- c_{ij} : Custo de atribuir a tarefa j ao agente i .
- a_{ij} : Carga da tarefa j quando executada pelo agente i .
- b_i : Capacidade máxima de carga do agente i .
- x_{ij} : Variável de decisão binária, que é 1 se a tarefa j for atribuída ao agente i , e 0 caso contrário.

DADOS DO PROBLEMA

Os dados do problema foram definidos de tal forma que número de agentes $m = 5$ e número de tarefas $n = 50$.

As capacidades máximas dos agentes são:

Agente i	Capacidade b_i
1	106.40
2	126.40
3	127.04
4	115.52
5	112.80

Tabela I: Capacidades máximas dos agentes

As matrizes de carga das tarefas quando atribuídas aos agentes é:

Ag/Tarefa	1	2	3	4	5	6	7	8	9	10
1	8	17	14	22	7	23	14	7	22	6
2	21	10	6	16	25	6	24	23	18	10
3	11	18	9	25	5	13	8	17	12	7
4	16	19	24	6	21	10	10	16	15	8
5	8	20	8	14	22	21	8	8	13	10

Tabela II: Amostra da matriz de carga a_{ij} (primeiras 10 tarefas)

As matrizes de custo das tarefas quando atribuídas aos agentes é:

Ag/Tarefa	1	2	3	4	5	6	7	8	9	10
1	22	37	11	25	36	14	20	50	47	10
2	38	17	33	28	25	34	21	39	46	27
3	37	15	46	50	17	19	35	24	43	22
4	32	50	37	16	27	25	20	33	20	16
5	38	17	17	45	29	33	43	14	34	17

Tabela III: Amostra da matriz de custo c_{ij} (primeiras 10 tarefas)

MODELO 1: MINIMIZAÇÃO DE CUSTO

Este modelo busca minimizar o custo total de alocação, considerando as restrições de capacidade de cada agente e a atribuição única de tarefas.

A função objetivo é:

$$\min \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \quad (1)$$

Sujeito às seguintes restrições:

$$\sum_{j=1}^n a_{ij}x_{ij} \leq b_i, \quad \forall i \in \{1, \dots, m\} \quad (2a)$$

$$\sum_{i=1}^m x_{ij} = 1, \quad \forall j \in \{1, \dots, n\} \quad (2b)$$

$$x_{ij} \in \{0, 1\}, \quad \forall i, j \quad (2c)$$

onde (2a) garante que a capacidade dos agentes não seja excedida, (2b) assegura que cada tarefa seja alocada a um único agente e (2c) define o domínio da variável.

MODELO 2: MINIMIZAÇÃO DA DIFERENÇA DE CARGA

Este modelo visa balancear a carga de trabalho entre os agentes, minimizando a diferença entre a carga do agente mais ocupado e a do menos ocupado. A função objetivo $f_E(\cdot)$, que representa este equilíbrio, é definida de forma não-linear como:

$$\min f_E(x) = \max_i \left(\sum_{j=1}^n a_{ij}x_{ij} \right) - \min_i \left(\sum_{j=1}^n a_{ij}x_{ij} \right) \quad (3)$$

Embora uma meta-heurística como o VNS possa avaliar esta função não-linear diretamente a cada iteração, a formulação padrão para a programação matemática — necessária para o uso de solvers exatos e para a comparação formal de resultados — exige a sua linearização. Esta é realizada com o uso de variáveis auxiliares: $L_{\max}$ para a carga máxima, $L_{\min}$ para a carga mínima, e D para a diferença entre elas. O modelo otimiza diretamente a variável D , resultando na seguinte formulação:

A função objetivo é:

$$\min D \quad (4)$$

Sujeito às restrições:

$$\sum_{j=1}^n a_{ij}x_{ij} \leq b_i, \quad \forall i \quad (5a)$$

$$\sum_{i=1}^m x_{ij} = 1, \quad \forall j \quad (5b)$$

$$\sum_{j=1}^n a_{ij}x_{ij} \leq L_{\max}, \quad \forall i \quad (5c)$$

$$\sum_{j=1}^n a_{ij}x_{ij} \geq L_{\min}, \quad \forall i \quad (5d)$$

$$D \geq L_{\max} - L_{\min} \quad (5e)$$

$$x_{ij} \in \{0, 1\}, \quad \forall i, j \quad (5f)$$

$$L_{\max}, L_{\min}, D \geq 0 \quad (5g)$$

As restrições (5a) e (5b) são as mesmas do modelo anterior. As restrições (5c) e (5d) forçam $L_{\max}$ e $L_{\min}$ a assumirem os valores de carga máxima e mínima, respectivamente. A restrição (5e) define a diferença, e (5f)-(5g) definem o domínio das variáveis.

III. ALGORITMO DE SOLUÇÃO

Nesta seção, detalhamos a abordagem meta-heurística desenvolvida para resolver as versões mono-objetivo do problema, justificando as escolhas de projeto com base em conceitos de otimização.

Estrutura da Meta-heurística e Vizinhanças

A meta-heurística adotada é uma variação do *Variable Neighborhood Search* (VNS), cuja ideia central é a mudança sistemática de vizinhanças para equilibrar duas forças essenciais: intensificação e diversificação. A intensificação foca na exploração detalhada de uma região promissora, enquanto a diversificação permite escapar de ótimos locais. Nossos três operadores de vizinhança foram escolhidos para desempenhar papéis distintos e complementares dentro desta filosofia.

Os dois primeiros operadores são responsáveis pela intensificação. A Realocação de uma tarefa (*Shift Move*) é o movimento mais fundamental e de menor custo computacional, análogo ao *Task Move*, permitindo um refinamento rápido da solução. A Troca de duas tarefas (*Swap Move*) é um movimento mais robusto, capaz de explorar a vizinhança de forma mais ampla que a simples realocação. A combinação destes dois operadores forma o núcleo da nossa fase de busca local intensiva.

O terceiro operador, a Perturbação aleatória de bloco, é o nosso mecanismo de diversificação. Ele implementa o paradigma *Ruin and Recreate*, onde uma parte da solução (10% das tarefas) é "destruída" e "reconstruída" aleatoriamente. A função deste movimento não é a melhoria imediata, mas sim forçar a busca a saltar para uma bacia de atração diferente no espaço de soluções, evitando a estagnação prematura.

Modelagem Computacional e Solução Inicial

Uma solução candidata é representada por um vetor x de dimensão n , em que cada elemento x_j indica o agente i responsável pela tarefa j . A busca se inicia com uma solução gerada por uma heurística construtiva gulosa, que atribui cada tarefa ao agente de menor custo (c_{ij}), desde que sua capacidade (b_i) não seja violada. Esta abordagem visa fornecer um ponto de partida de alta qualidade para acelerar a convergência.

Busca Local e Tratamento de Restrições

A busca local do nosso algoritmo é implementada pela Estratégia de Refinamento, que consiste em um procedimento de reparo guloso. Esta estratégia é fundamental para o tratamento das restrições de capacidade do problema.

A abordagem adotada é a de Métodos de Reparo. Em vez de simplesmente rejeitar soluções infactíveis, uma prática que pode limitar a exploração do espaço de busca, nosso algoritmo permite que os operadores de vizinhança gerem soluções temporariamente inviáveis. Imediatamente após a geração de um vizinho, a busca local (reparo guloso) é acionada. Ela identifica os agentes sobrecarregados e realoca suas tarefas para outros com capacidade disponível, de forma a restaurar a factibilidade e, ao mesmo tempo, otimizar a função objetivo.

Este processo de "gerar e reparar" permite que a busca atravessasse "pontes" de inviabilidade para conectar diferentes regiões factíveis, aumentando o poder de exploração do algoritmo.

IV. OTIMIZAÇÃO MONO-OBJETIVO

Nesta seção, apresentaremos os resultados obtidos nas otimizações mono-objetivos, entre outras informações interessantes sobre o problema. O teste de convergência de cada função mono-objetivo foi avaliado para 5 amostras e para 10000 iterações, apresentando as seguintes curvas para f_1 e f_2 . Os resultados da otimização mono-objetiva foram:

Tabela IV: Resultados da Otimização Focada em Custo (f_1)

Execução	Custo (f_1)	Dif. Carga Corresp. (f_2)
1	935.00	18.00
2	908.00	28.00
3	903.00	22.00
4	904.00	22.00
5	917.00	21.00
Mín: 903.00, Máx: 935.00, Média: 913.40, DP: 11.88		

Tabela V: Resultados da Otimização Focada em Diferença (f_2)

Execução	Custo Corresp. (f_1)	Diferença de Carga (f_2)
1	1272.00	3.00
2	1384.00	0.00
3	1385.00	2.00
4	1290.00	3.00
5	1267.00	2.00
Mín: 0.00, Máx: 3.00, Média: 2.00, DP: 1.10		

As curvas de convergência estão disponibilizadas abaixo:




Figura 1: Convergência em f_1




Figura 2: Convergência em f_2

Os dois gráficos possuem comportamento semelhante, uma otimização acentuada no início e certa estabilização ao longo das iterações, com otimização ainda pendente em 10000 iterações.

Análise das Melhores Soluções Encontradas

Para ilustrar as características das melhores soluções, foram gerados gráficos que representam a distribuição de carga e custo entre os agentes. Estes gráficos permitem uma análise visual clara do *trade-off* entre os dois objetivos conflitantes.




Figura 3: Análise da melhor solução para o objetivo de Custo (f_1). Observa-se um desequilíbrio na carga (a), consequência da priorização do custo mínimo, que também se distribui de forma desigual entre os agentes (b).




Figura 4: Análise da melhor solução para o objetivo de Equilíbrio (f_2). As cargas de trabalho (a) são visivelmente homogêneas, demonstrando o sucesso em balancear a distribuição, em detrimento de um custo total mais elevado e distribuído de forma diferente (b).

Outros Testes

Também foram realizados testes para avaliar a influência de cada estrutura de vizinhança sobre a convergência do modelo, para isso, foi testada uma vez cada função e utilizada apenas a estrutura de vizinhança a ser avaliada.

Para o primeiro teste, foi considerado apenas a estrutura de vizinhança da realocação de uma tarefa aleatória para um agente diferente.




Figura 5: Influência da Estrutura de Vizinhança 1

Para o segundo teste, foi considerado apenas a estrutura de vizinhança da realocação da troca ou swap de duas tarefas.




Figura 6: Influência da Estrutura de Vizinhança 2

Para o terceiro teste, foi considerado apenas a perturbação aleatória do bloco.




Figura 7: Influência da Estrutura de Vizinhança 3

Para todos os estes é possível perceber que a solução ótima permanece distante para a estrutura de vizinhança 1 e 3, enquanto a 2 parece mais influente ao encontrar a solução ótima. Este resultado experimental corrobora a análise teórica: os operadores de realocação (Vizinhança 1) e perturbação (Vizinhança 3), quando isolados, são insuficientes. O primeiro por ser muito restrito e o segundo por não possuir um viés de melhoria. O operador de troca (Vizinhança 2) atinge um bom equilíbrio entre poder de exploração e refinamento, mas a performance superior do algoritmo completo demonstra

a sinergia da combinação estratégica entre intensificação e diversificação.

O espaço definido pelo resultado da otimização de 10 funções mono-objetivos de cada uma foi plotado a seguir. A dispersão dos pontos ilustra a variabilidade inerente ao método estocástico e evidencia claramente o trade-off entre os objetivos: soluções com menor custo tendem a apresentar maior desequilíbrio de carga, e vice-versa.




Figura 8: Espaço das Soluções de otimização com 5 pontos

V. OTIMIZAÇÃO MULTI-OBJETIVO

Nesta seção, apresentaremos a modelagem do problema como soma ponderada e ϵ -restrito e apresentaremos os resultados da implementação dos algoritmos.

Para ambas as abordagens, é fundamental definir os pontos de referência que delimitam o espaço de objetivos, obtidos a partir dos resultados da otimização mono-objetivo (Tabelas IV e V). Estes pontos formam a Matriz Payoff, que define os limites do espaço de soluções. O Ponto Utopia (z^*) é composto pelos melhores valores de cada objetivo, sendo $z^* = (f_1^{\min}, f_2^{\min}) = (903.00, 0.00)$. O Ponto Nadir (z^{nad}) é composto pelos piores valores de cada objetivo durante a otimização do outro, sendo $z^{\text{nad}} = (f_1^{\max}, f_2^{\max}) = (1385.00, 28.00)$. Estes valores são parâmetros essenciais tanto para a normalização na Soma Ponderada quanto para definir o intervalo de variação no ϵ -Restrito.

Método da Soma Ponderada (Pw)

Este método transforma o problema multi-objetivo em mono-objetivo através da soma ponderada dos objetivos. Como f_1 (Custo) e f_2 (Diferença de Carga) possuem escalas distintas, a normalização dos objetivos é mandatória para que os pesos w_1 e w_2 reflitam corretamente a importância dada a cada função. A modelagem matemática final é:

$$\min P_w(\mathbf{x}) = w_1 \cdot f_1^{\text{norm}}(\mathbf{x}) + w_2 \cdot f_2^{\text{norm}}(\mathbf{x}) \quad (6)$$

Sujeito a:

$$w_1 + w_2 = 1, \quad w_1, w_2 \geq 0 \quad (7a)$$

$$\sum_{i=1}^m x_{ij} = 1, \quad \forall j \quad (7b)$$

$$\sum_{j=1}^n a_{ij} x_{ij} \leq b_i, \quad \forall i \quad (7c)$$

$$x_{ij} \in \{0, 1\} \quad (7d)$$

Onde as restrições (7b)-(7d) são as restrições originais do GAP. Os objetivos normalizados $f_k^{\text{norm}}(\mathbf{x})$ são calculados pela fórmula:

$$f_k^{\text{norm}}(\mathbf{x}) = \frac{f_k(\mathbf{x}) - f_k^{\min}}{f_k^{\max} - f_k^{\min}}, \quad \text{para } k = 1, 2$$

Substituindo os valores da Matriz Payoff, as funções objetivo específicas para este problema são:

$$f_1^{\text{norm}}(\mathbf{x}) = \frac{f_1(\mathbf{x}) - 903.00}{1385.00 - 903.00} \quad (8)$$

$$f_2^{\text{norm}}(\mathbf{x}) = \frac{f_2(\mathbf{x}) - 0.00}{28.00 - 0.00} \quad (9)$$

Abordagem ϵ -Restrito (P_ϵ)

Este método minimiza o objetivo primário (f_1) enquanto trata o segundo objetivo (f_2) como uma restrição adicional, limitada por um valor ϵ_k . Esta abordagem é particularmente útil para encontrar soluções em partes não-convexas da fronteira de Pareto.

$$\min P_\epsilon(\mathbf{x}) = f_1(\mathbf{x}) \quad (10)$$

Sujeito a:

$$f_2(\mathbf{x}) \leq \epsilon_k \quad (11a)$$

$$\sum_{i=1}^m x_{ij} = 1, \quad \forall j \quad (11b)$$

$$\sum_{j=1}^n a_{ij} x_{ij} \leq b_i, \quad \forall i \quad (11c)$$

$$x_{ij} \in \{0, 1\} \quad (11d)$$

Onde ϵ_k é variado no intervalo $[f_2^{\min}, f_2^{\max}]$ (ou seja, de 0.00 a 28.00) para mapear a fronteira.

Adaptação do VNS para Abordagens Escalares

Para resolver os problemas biobjetivos, o algoritmo VNS proposto na Seção III foi adaptado. A estrutura de busca (vizinhanças, reparo) foi mantida, mas a função de *fitness* (usada para aceitar ou rejeitar novas soluções) foi substituída para refletir cada abordagem escalar.

A principal adaptação reside em como as restrições do problema são tratadas. Os modelos matemáticos P_w e P_ϵ tratam as restrições (7c) e (11a) como "rígidas" (*hard constraints*). Para uma meta-heurística como o VNS, que explora o espaço de busca através de movimentos locais, esta abordagem é ineficaz,

pois "prenderia" a busca e a impediria de explorar soluções promissoras que estejam temporariamente inviáveis.

A solução implementada, que é a forma padrão de aplicar meta-heurísticas a problemas restritos, é converter estas restrições rígidas em "suaves" (*soft constraints*) através de funções de penalidade.

VNS para Soma Ponderada (P_w): Para esta abordagem, a função de *fitness* do VNS tornou-se a própria função objetivo escalarizada (Equação 10), acrescida da penalidade por violação de capacidade:

$$\min \text{fitness}(\mathbf{x}) = P_w(\mathbf{x}) + \rho \cdot \sum_{i=1}^m \max(0, \text{Carga}_i - b_i)$$

onde ρ é um alto fator de penalidade. O VNS é então executado 200 vezes, variando w_1 de 0 a 1, para gerar a fronteira.

VNS para ϵ -Restrito (P_ϵ): Para a abordagem P_ϵ , a função de *fitness* minimiza o objetivo f_1 (Equação 10) e adiciona dois termos de penalidade: um para a restrição de capacidade original e outro para a nova restrição ϵ (Equação 11a):

$$\begin{aligned} \min \text{fitness}(\mathbf{x}) = f_1(\mathbf{x}) + \rho \cdot \sum_{i=1}^m \max(0, \text{Carga}_i - b_i) \\ + \rho_\epsilon \cdot \max(0, f_2(\mathbf{x}) - \epsilon_k) \end{aligned}$$

onde ρ_ϵ é um fator de penalidade de ϵ . Esta abordagem permite que o VNS explore soluções que violem ligeiramente o ϵ_k , mas a alta penalidade o guia de volta à região factível, garantindo que a solução final encontrada respeite o limite ϵ estabelecido. O VNS é executado 200 vezes, variando ϵ_k no intervalo $[0.00, 28.00]$.

Análise das Fronteiras Encontradas

Para analisar os resultados da otimização multiobjetivo, foram gerados dois conjuntos de gráficos. O primeiro (Figuras 9 e 10) compara a variabilidade estocástica das 5 execuções, enquanto o segundo (Figuras 11 e 12) apresenta a fronteira de Pareto final filtrada.

Análise de Variabilidade: Na abordagem da Soma Ponderada (Fig. 10), os resultados são claros. As 5 execuções (representadas por cores diferentes), embora estocásticas, convergiram para a mesma região e formam um contorno bem definido da fronteira de Pareto. Isso demonstra a robustez do VNS para esta abordagem, encontrando consistentemente soluções de alta qualidade ao longo da fronteira.

Em contrapartida, o gráfico do ϵ -Restrito (Fig. 9) apresenta um comportamento diferente. Embora à primeira vista pareça mais ruidoso que a Soma Ponderada, este comportamento é o esperado para esta metodologia. O método explora o espaço de busca para cada ϵ_k (limite de f_2), e o VNS tenta minimizar f_1 (Custo). O gráfico mostra que o algoritmo encontra muitas soluções dominadas (pontos "acima" da fronteira) durante o processo de busca em cada "faixa" de ϵ_k . No entanto, a borda inferior esquerda dos pontos forma claramente a fronteira de

Pareto, indicando que o método foi bem-sucedido em mapear as soluções não-dominadas.




Figura 9: Evolução da Fronteira Pareto no ϵ -restrito




Figura 10: Evolução da Fronteira Pareto na Soma Ponderada

Análise da Fronteira Final: As Figuras 11 e 12 foram geradas agregando-se todas as 1000 soluções (5 execuções $\times$ 200 pontos) de cada abordagem e aplicando um filtro de não-dominância.

Conforme a saída dos resultados, o filtro de não-dominância encontrou 10 soluções para a Soma Ponderada e 10 soluções para o ϵ -Restrito. Todas as soluções não-dominadas encontradas foram plotadas.

Tabela VI: Soluções Não-Dominadas da Soma Ponderada (P_w)

Custo (f_1)	Diferença de Carga (f_2)
899.00	15.00
901.00	14.00
902.00	8.00
903.00	7.00
893.00	19.00
915.00	4.00
924.00	3.00
953.00	2.00
963.00	1.00
1052.00	0.00

Tabela VII: Soluções Não-Dominadas do ϵ -Restrito (P_ϵ)

Custo (f_1)	Diferença de Carga (f_2)
889.00	20.00
896.00	16.00
900.00	12.00
902.00	11.00
909.00	10.00
910.00	7.00
968.00	6.00
997.00	4.00
1140.00	1.00
1155.00	0.00




Figura 11: Fronteira Pareto Ótima ϵ -restrito (10 soluções)




Figura 12: Fronteira Pareto Ótima Soma Ponderada (10 soluções)

A análise destas fronteiras finais confirma o forte *trade-off* entre os objetivos, evidenciado pela curvatura acentuada. Melhorias no custo (f_1) exigem grandes sacrifícios no equilíbrio de carga (f_2), e vice-versa. Por exemplo, na fronteira da Soma Ponderada (Fig. 12), a solução (Custo 953.00, Dif. 2.00) pode ser comparada com a solução (Custo 915.00, Dif. 4.00). Uma redução de 4.0% no custo (de 953 para 915) resultou em um aumento de 100% na diferença de carga (de 2 para 4).

Ambas as abordagens identificaram fronteiras de forma convexa. A teoria afirma que a Soma Ponderada só é garantida a encontrar a fronteira completa em problemas convexas. O sucesso do P_w em mapear a fronteira (Fig. 12) é uma forte evidência experimental de que a fronteira Pareto-ótima desta instância do problema é, de fato, convexa. O método ϵ -Restrito (Fig. 11), que também lida com não-convexidades, naturalmente também obteve sucesso.

É interessante notar que ambas as fronteiras encontraram soluções idênticas ou muito próximas em certas regiões, como (Custo 902.00, Dif. 8.00/11.00) e (Custo 910.00, Dif. 7.00), que aparecem com valores similares em ambas as listas. No entanto, elas divergem nos extremos. A Soma Ponderada encontrou uma solução de diferença zero (Custo 1052.00, Dif. 0.00) que domina a melhor solução de diferença zero do ϵ -Restrito (Custo 1155.00, Dif. 0.00). No outro extremo, o ϵ -Restrito encontrou uma solução de menor custo (Custo 889.00, Dif. 20.00) que a Soma Ponderada não alcançou. Isso sugere que, embora a fronteira seja convexa, a amostragem de soluções de ambos os métodos é complementar.

VI. TOMADA DE DECISÃO MULTICRITÉRIO

Nesta seção, apresentamos a aplicação de métodos de auxílio à decisão para selecionar a solução final a ser implementada. A decisão não se baseia apenas nos dois objetivos otimizados (f_1 e f_2), mas também em atributos adicionais que capturam aspectos importantes da qualidade das soluções.

Definição dos Atributos de Decisão

Para uma análise mais completa, foram definidos quatro atributos conflitantes. Os dois primeiros correspondem aos objetivos já otimizados: f_1 representa o custo total, que deve ser minimizado, enquanto f_2 representa a diferença de carga entre agentes, também a ser minimizada.

Além destes, dois atributos adicionais foram definidos para capturar dimensões importantes não consideradas na otimização. O atributo f_3 representa o risco total, calculado como a soma das probabilidades de falha das tarefas alocadas, e deve ser minimizado. O atributo f_4 representa a satisfação média dos agentes com as tarefas atribuídas, e deve ser maximizado. É fundamental destacar que f_3 e f_4 foram modelados de forma independente dos objetivos otimizados f_1 e f_2 , garantindo que a decisão multicritério considere dimensões ortogonais do problema.

Modelagem dos Atributos Adicionais: A modelagem do risco total (f_3) considera que cada par agente-tarefa (i, j) possui uma probabilidade de falha r_{ij} no intervalo $[0.05, 0.95]$. Esta probabilidade é determinada por três fatores principais. Primeiro, a competência do agente cmp_i , que representa sua habilidade geral e é gerada aleatoriamente no intervalo $[0.3, 0.9]$, sendo ajustada pelo custo médio normalizado do agente. Segundo, a complexidade da tarefa $cplx_j$, calculada como $cplx_j = 0.3 + 0.5 \cdot \frac{\bar{a}_j}{\max_k \bar{a}_k}$, onde $\bar{a}_j$ é a carga média da tarefa j entre todos os agentes. Terceiro, o fator de especialização, onde cada agente possui especialidade em aproximadamente 20% das tarefas, reduzindo o risco em 0.5 pontos quando executa uma tarefa de sua especialidade.

O risco de cada alocação é então calculado pela expressão:

$$r_{ij} = 0.15 + (1 - cmp_i) \times 0.4 + cplx_j \times 0.3 - esp_{ij} \times 0.5 + \xi$$

onde $\xi \sim U(-0.08, 0.08)$ é um ruído aleatório que adiciona variabilidade. O risco total de uma solução $\mathbf{x}$ é simplesmente a soma dos riscos individuais:

$$f_3(\mathbf{x}) = \sum_{j=1}^n r_{x_j, j} \quad (12)$$

A modelagem da satisfação média (f_4) considera que cada par agente-tarefa (i, j) possui um nível de satisfação s_{ij} no intervalo $[0, 100]$. Esta satisfação depende primariamente do perfil comportamental do agente. Os agentes foram classificados em três categorias de acordo com suas preferências: agentes desafiadores (20% do total) que preferem tarefas complexas e pesadas, agentes balanceados (50%) que preferem tarefas de complexidade média, e agentes confortáveis (30%) que preferem tarefas simples e leves. Adicionalmente, cada agente possui um conjunto de aproximadamente 15% das tarefas como favoritas, o que aumenta sua satisfação em 25 pontos quando uma destas tarefas lhe é atribuída.

A satisfação de cada alocação é calculada como:

$$s_{ij} = s_{base} + s_{perfil}(a_{ij}) + s_{favorita} + \eta$$

onde $s_{base} \sim U(35, 75)$ é uma satisfação base aleatória e $\eta \sim U(-10, 10)$ é um ruído. A satisfação média de uma solução $\mathbf{x}$ é dada por:

$$f_4(\mathbf{x}) = \frac{1}{n} \sum_{j=1}^n s_{x_j, j} \quad (13)$$

Conflito entre os Atributos: Os quatro atributos definidos são genuinamente conflitantes, o que justifica a necessidade de métodos multicritério para a tomada de decisão. A minimização de f_1 (custo) tende a alocar tarefas aos agentes mais baratos, que frequentemente são menos experientes ou especializados, resultando em aumento de f_3 (risco). Por outro lado, a minimização de f_2 (diferença de carga) busca equilibrar a distribuição de trabalho, o que pode forçar a alocação de tarefas fora das especialidades dos agentes, reduzindo f_4 (satisfação).

De forma complementar, a minimização de f_3 (risco) requer alocar tarefas preferencialmente aos especialistas mais competentes, que tendem a ser mais caros, aumentando f_1 (custo). Finalmente, a maximização de f_4 (satisfação) requer respeitar as preferências pessoais de cada agente, incluindo suas tarefas favoritas, o que naturalmente pode criar desequilíbrios na distribuição, aumentando f_2 (diferença de carga). Esta teia de conflitos demonstra que não existe uma solução obviamente superior, tornando essencial o uso de métodos estruturados de decisão.

Conjunto de Alternativas

Para a tomada de decisão, foram combinadas as fronteiras de Pareto obtidas pelas abordagens Soma Ponderada e ϵ -Restrito, apresentadas nas Tabelas VI e VII. Das 20 soluções únicas identificadas (10 da Soma Ponderada e 11 do ϵ -Restrito, com sobreposição), após remoção de duplicatas e aplicação de um filtro de não-dominância considerando os dois objetivos

originais, obtiveram-se 12 soluções não-dominadas. Estas 12 soluções foram então avaliadas em todos os quatro atributos.

Para cada uma das 12 soluções candidatas, os valores dos quatro atributos (f_1, f_2, f_3, f_4) foram calculados e compilados em uma matriz de decisão. As estatísticas descritivas dos atributos, apresentadas na Tabela VIII, revelam a amplitude de variação em cada dimensão: o custo varia de 889.00 a 1052.00, a diferença de carga de 0.00 a 20.00, o risco de 20.50 a 23.08, e a satisfação de 57.54 a 59.92.

Tabela VIII: Estatísticas dos Atributos nas Soluções Analisadas

Estatística	f_1 (Custo)	f_2 (Dif.)	f_3 (Risco)	f_4 (Satisf.)
Mínimo	889.00	0.00	20.50	57.54
Máximo	1052.00	20.00	23.08	59.92
Média	924.08	8.92	21.73	58.69
Desv. Pad	46.63	7.23	0.84	0.75

Métodos de Decisão Aplicados

Dois métodos multicritério foram aplicados para selecionar a solução final: o AHP (*Analytic Hierarchy Process*) e o ELECTRE II (*Elimination and Choice Translating Reality*). A escolha destes métodos se justifica por suas naturezas complementares: o AHP é um método compensatório que permite *trade-offs* entre critérios, enquanto o ELECTRE II é não-compensatório e baseado em relações de superação, sendo mais cauteloso quanto a compensações entre atributos.

Método AHP: O AHP é um método compensatório baseado em comparações pareadas que permite determinar a importância relativa dos critérios. A unidade de decisão, representada pelos autores deste trabalho, definiu suas prioridades através de uma matriz de comparação pareada. Esta matriz reflete o julgamento de que o custo (f_1) é o fator mais importante, seguido pelo risco (f_3), e que a diferença de carga (f_2) e a satisfação (f_4) têm importância relativamente menor e equivalente entre si.

Especificamente, a matriz de comparação utilizada foi:

$$A = \begin{bmatrix} 1 & 3 & 2 & 3 \\ 1/3 & 1 & 1/2 & 1 \\ 1/2 & 2 & 1 & 2 \\ 1/3 & 1 & 1/2 & 1 \end{bmatrix} \quad (14)$$

onde as linhas e colunas correspondem a f_1, f_2, f_3 e f_4 , respectivamente. Esta matriz indica que o custo é considerado três vezes mais importante que a diferença de carga e a satisfação, e duas vezes mais importante que o risco. Por sua vez, o risco é considerado duas vezes mais importante que a diferença de carga e a satisfação. A hierarquia de prioridades estabelecida é, portanto: Custo > Risco > Diferença $\approx$ Satisfação.

A escolha de utilizar valores moderados na escala de Saaty (1 a 3, em vez de valores extremos como 7 ou 9) foi deliberada e fundamenta-se em três razões principais. Primeiro, preferências moderadas tendem a produzir matrizes com menor inconsistência, como evidenciado pela razão de consistência obtida ($CR = 0.0038$), muito inferior ao limite aceitável de

0.10. Segundo, valores extremos na escala de Saaty (como 7 ou 9) implicam que um critério é “muito fortemente” ou “extremamente” mais importante que outro, o que raramente reflete cenários reais de decisão empresarial onde múltiplos fatores possuem relevância comparável. Terceiro, a utilização de preferências moderadas resulta em pesos mais equilibrados, evitando que um único critério domine excessivamente a função de agregação e permitindo que *trade-offs* entre critérios sejam adequadamente capturados.

Aplicando o método do autovetor principal à matriz de comparação, foram calculados os pesos apresentados na Tabela IX. O custo recebeu o maior peso (0.4554), seguido pelo risco (0.2628), diferença de carga (0.1409) e satisfação (0.1409). Nota-se que f_2 e f_4 obtiveram pesos idênticos, refletindo a equivalência estabelecida na matriz de comparação. A razão de consistência calculada foi $CR = 0.0038$, muito abaixo do limite aceitável de 0.10, indicando alta consistência nas comparações pareadas realizadas.

Tabela IX: Pesos dos Critérios (AHP)

Atributo	Peso (w_i)
f_1 (Custo)	0.4554
f_2 (Diferença)	0.1409
f_3 (Risco)	0.2628
f_4 (Satisfação)	0.1409

Para o cálculo dos *scores* finais, as 12 alternativas foram primeiro normalizadas no intervalo $[0, 1]$ usando normalização min-max, considerando as direções apropriadas de otimização (valores menores são melhores para f_1, f_2 e f_3 , enquanto valores maiores são melhores para f_4). Os *scores* finais foram então calculados como a soma ponderada dos valores normalizados, permitindo a ordenação das alternativas.

Método ELECTRE II: O ELECTRE II é um método não-compensatório fundamentado no conceito de relações de superação. Diferentemente do AHP, que permite que um desempenho muito bom em um critério compense um desempenho ruim em outro, o ELECTRE estabelece relações binárias de superação entre pares de alternativas baseadas em concordância e discordância.

Para cada par de alternativas (a, b) , dois índices são calculados. O índice de concordância $C(a, b)$ representa o peso total dos critérios nos quais a alternativa a tem desempenho igual ou superior a b , sendo calculado como:

$$C(a, b) = \sum_{k: f_k(a) \geq f_k(b)} w_k$$

onde os pesos w_k utilizados foram os mesmos obtidos pelo AHP, garantindo consistência na importância relativa dos critérios. O índice de discordância $D(a, b)$ representa a maior diferença normalizada desfavorável a a , calculado como:

$$D(a, b) = \max_{k: f_k(a) < f_k(b)} (f_k^{norm}(b) - f_k^{norm}(a))$$

Uma alternativa a é considerada superior a b (denotado aSb) quando dois critérios são simultaneamente satisfeitos:

a concordância deve ser suficientemente alta ($C(a, b) \geq p$) e a discordância deve ser suficientemente baixa ($D(a, b) \leq q$). Os valores de limiar utilizados foram $p = 0.65$ para concordância e $q = 0.35$ para discordância, valores típicos que equilibram rigor e flexibilidade na construção das relações de superação. Com estes limiares, foram identificadas 12 relações de superação entre as alternativas.

O ranking final foi obtido através do cálculo do *net flow score*, definido como:

$$\text{Score}(a) = \sum_{b \neq a} aSb - \sum_{b \neq a} bSa$$

Este *score* representa quantas alternativas a supera menos quantas alternativas a superam, fornecendo uma medida clara de dominância relativa.

Resultados e Análise Comparativa

A aplicação dos métodos AHP e ELECTRE II às 12 soluções candidatas produziu rankings que, embora apresentem sobreposição significativa, divergiram na solução indicada como primeira colocada. O método AHP selecionou a Solução #8 como ótima, enquanto o ELECTRE II elegeu a Solução #2. As cinco melhores soluções de cada método são apresentadas nas Tabelas X e XI.

Tabela X: TOP 5 Soluções - Método AHP

Pos.	ID	Score	f_1	f_2	f_3	f_4
1°	8	0.7854	899.00	15.00	20.50	58.55
2°	2	0.7513	915.00	4.00	21.42	59.00
3°	1	0.7249	953.00	2.00	21.31	59.92
4°	4	0.7245	903.00	7.00	22.09	59.46
5°	11	0.7242	889.00	20.00	21.53	59.38

Tabela XI: TOP 5 Soluções - Método ELECTRE II

Pos.	ID	f_1	f_2	f_3	f_4	Score
1°	2	915.00	4.00	21.42	59.00	3
2°	1	953.00	2.00	21.31	59.92	2
3°	8	899.00	15.00	20.50	58.55	2
4°	4	903.00	7.00	22.09	59.46	1
5°	10	896.00	16.00	20.91	57.72	1

A análise dos rankings revela uma convergência interessante: a Solução #2 aparece em segundo lugar no AHP e em primeiro no ELECTRE II, enquanto a Solução #8 aparece em primeiro no AHP e em terceiro no ELECTRE II (empatada em segundo lugar pelo *score*). Esta divergência reflete as diferentes filosofias dos métodos: o AHP, sendo compensatório, premia a Solução #8 por seu excelente desempenho combinado em custo ($f_1 = 899.00$) e risco ($f_3 = 20.50$), mesmo com diferença de carga relativamente alta ($f_2 = 15.00$). O ELECTRE II, sendo mais conservador quanto a compensações, privilegia a Solução #2 por seu excelente equilíbrio de carga ($f_2 = 4.00$), construindo mais relações de superação sobre outras alternativas.

Para resolver esta divergência, foi realizada uma comparação direta entre as duas soluções candidatas

nos quatro atributos, apresentada na Tabela XII. A Solução #8 (indicada pelo AHP) mostra-se superior em dois atributos: possui custo 1.7% menor (899.00 contra 915.00) e risco 4.3% menor (20.50 contra 21.42). Por outro lado, a Solução #2 (indicada pelo ELECTRE) também é superior em dois atributos: apresenta diferença de carga 73% menor (4.00 contra 15.00) e satisfação 0.8% maior (59.00 contra 58.55). O resultado desta comparação é um empate técnico, com cada solução vencendo em dois dos quatro critérios.

Tabela XII: Comparação entre as Soluções Indicadas

Atributo	AHP (#8)	ELECTRE (#2)	Melhor
f_1 (Custo)	899.00	915.00	AHP
f_2 (Diferença)	15.00	4.00	ELECTRE
f_3 (Risco)	20.50	21.42	AHP
f_4 (Satisfação)	58.55	59.00	ELECTRE
Placar	2	2	EMPATE

Critério de Desempate e Decisão Final

Diante do empate técnico observado (duas vitórias para cada solução candidata), tornou-se necessário estabelecer um critério adicional de desempate. Após análise cuidadosa do contexto operacional do problema, estabeleceu-se que a minimização do risco total (f_3) seria utilizada como critério de desempate.

A escolha deste critério fundamenta-se na criticidade da confiabilidade operacional em ambientes empresariais. Falhas na execução de tarefas podem gerar uma cascata de consequências negativas que vão além do custo imediato de retrabalho. Estas incluem custos adicionais de correção e reexecução, potenciais penalidades contratuais decorrentes do descumprimento de prazos, danos significativos à reputação organizacional perante clientes e parceiros, e deterioração da satisfação de clientes e *stakeholders*. Em um contexto onde a confiabilidade é um ativo estratégico, a escolha da solução de menor risco torna-se natural.

Aplicando este critério, observa-se que a Solução #8 apresenta risco total de 20.50, enquanto a Solução #2 apresenta 21.42. Esta diferença de 0.92 pontos representa uma redução de 4.3% no risco, o que em termos práticos significa aproximadamente uma tarefa a menos com probabilidade elevada de falha. Este é um ganho significativo em termos de confiabilidade operacional.

A escolha da Solução #8 implica em aceitar certos *trade-offs* em relação à Solução #2. A diferença de carga passa de 4.00 para 15.00, um aumento de 275%, indicando uma distribuição consideravelmente menos equilibrada do trabalho entre os agentes. A satisfação média também sofre uma pequena redução, passando de 59.00 para 58.55, uma queda de 0.8%. Em contrapartida, além da já mencionada redução de 4.3% no risco, obtém-se também uma economia de custo de \$16.00, equivalente a uma redução de 1.7%.

Assim, a decisão final recai sobre a Solução #8, indicada pelo método AHP, por apresentar o melhor perfil de custo-confiabilidade. Esta escolha reflete uma estratégia que prioriza

a eficiência econômica e a robustez operacional, aceitando um desequilíbrio moderado na distribuição de carga e uma leve redução na satisfação dos agentes. Em um contexto onde a prevenção de falhas é valorizada, esta é uma decisão estrategicamente alinhada com princípios de gestão de risco.

Visualização da Solução Final

A Figura 13 apresenta a fronteira de Pareto completa com as soluções escolhidas pelos dois métodos destacados. A Solução #8 (AHP), marcada por uma estrela vermelha, situa-se em uma região de compromisso equilibrado entre custo e diferença de carga. A Solução #2 (ELECTRE), marcada por um quadrado verde, localiza-se em uma região que privilegia fortemente o equilíbrio de carga, aceitando um custo ligeiramente maior. A visualização confirma que ambas as soluções são não-dominadas e representam escolhas válidas, cada uma refletindo um perfil de prioridades diferente.




Figura 13: Fronteira de Pareto com soluções selecionadas pelos métodos multicritério. A solução AHP (#8) foi escolhida como solução final.

A análise de *trade-offs* entre os quatro atributos é apresentada na Figura 14 através de quatro gráficos de dispersão. Os gráficos evidenciam as correlações esperadas: a redução de custo tende a aumentar o risco (gráfico superior esquerdo), a redução de custo correlaciona-se negativamente com a satisfação (gráfico superior direito), o equilíbrio de carga tende a aumentar o risco (gráfico inferior esquerdo), e há uma relação inversa entre risco e satisfação (gráfico inferior direito). A coloração dos pontos por um terceiro atributo em cada gráfico permite visualizar as interdependências entre múltiplas dimensões simultaneamente.




Figura 14: Análise de *trade-offs* entre os quatro atributos de decisão nas soluções não-dominadas.

Características da Solução Final

A Solução #8 apresenta um perfil operacional equilibrado, com métricas apresentadas na Tabela XIII. O custo total de 899.00 representa o segundo menor custo entre todas as soluções analisadas, ficando apenas 10 unidades acima do mínimo de 889.00. A diferença de carga de 15.00, embora não seja a menor da fronteira, ainda representa uma distribuição aceitável. O risco total de 20.50 é o menor entre todas as alternativas avaliadas, confirmando a robustez desta solução. A satisfação média de 58.55 situa-se próxima à média do conjunto de soluções (58.69), indicando um desempenho médio neste atributo.

Tabela XIII: Métricas da Solução Final

Métrica	Valor
Custo Total (f_1)	899.00
Diferença de Carga (f_2)	15.00
Risco Total (f_3)	20.50
Satisfação Média (f_4)	58.55
Taxa de Utilização Média	85.3%
Coef. Variação da Carga	12.4%

A distribuição detalhada de carga e custo por agente é apresentada na Figura 15. O gráfico da esquerda mostra a carga alocada a cada agente (barras coloridas) em comparação com suas capacidades máximas (linha vermelha tracejada). Todos os cinco agentes operam dentro de suas capacidades, com taxas de utilização variando entre 75% e 95%, indicando que a solução é factível e utiliza bem a capacidade disponível. O gráfico da direita mostra a distribuição de custos entre os agentes, revelando que o Agente 1 incorre no maior custo individual, enquanto os demais apresentam custos distribuídos de forma mais homogênea. Esta distribuição reflete as características da solução, que busca minimizar o custo global respeitando as restrições de capacidade.




Figura 15: Distribuição de carga e custo por agente na solução final. Todos os agentes respeitam suas capacidades máximas (linha vermelha tracejada).

VII. CONCLUSÃO

Este trabalho abordou o Problema de Atribuição Generalizada (GAP) através de uma abordagem completa envolvendo otimização mono-objetivo, multi-objetivo e tomada de decisão multicritério.

Na etapa de otimização mono-objetivo, o algoritmo VNS demonstrou eficácia em explorar o espaço de soluções através de três estruturas de vizinhança complementares. A análise individual das vizinhanças confirmou que a sinergia entre os operadores de intensificação (realocação e troca) e diversificação (perturbação) é fundamental para o desempenho do algoritmo.

A otimização multi-objetivo revelou o forte *trade-off* entre custo e equilíbrio de carga. Ambas as abordagens escalares (Soma Ponderada e ϵ -Restrito) mapearam com sucesso a fronteira de Pareto, que se mostrou convexa, permitindo a identificação de 12 soluções não-dominadas bem distribuídas.

A etapa de tomada de decisão multicritério incorporou dois atributos adicionais, risco de falha e satisfação dos agentes, que capturam dimensões importantes não consideradas na otimização. A aplicação dos métodos AHP e ELECTRE II, com priorização de custo e confiabilidade, resultou na seleção de uma solução balanceada (Custo = 899.00, Diferença = 15.00, Risco = 20.50, Satisfação = 58.55) que representa um compromisso robusto entre eficiência econômica e confiabilidade operacional.

O trabalho demonstrou a importância de integrar múltiplos critérios na decisão final, indo além da simples otimização bi-objetivo e considerando aspectos qualitativos relevantes ao contexto de aplicação. Trabalhos futuros podem explorar abordagens de otimização multi-objetivo não-escalares (como algoritmos evolutivos) e métodos de decisão em grupo para incorporar múltiplas perspectivas de *stakeholders*.